

# Kapitel ADS:IV

## IV. Datenstrukturen

- ☐ Record
- ☐ Linear List
- ☐ Linked List
- ☐ Stack
- ☐ Queue
- ☐ Priority Queue
- ☐ Dictionary
- ☐ Direct-address Table
- ☐ Hash Table
- ☐ Hash Function

# Hash Function

## Definition

Eine Hash Function (*Hashfunktion*)

$$h : U \rightarrow \{0, 1, \dots, m - 1\}$$

bildet ein Universum  $U$  von Schlüsseln beliebigen Typs auf  $m$  natürliche Zahlen ab.

Eigenschaften:

- ❑ total: Jeder Schlüssel  $k$  aus  $U$  hat genau einen Funktionswert  $h(k)$  in  $\{0, 1, \dots, m - 1\}$ .
- ❑ surjektiv: Für alle  $y \in \{0, 1, \dots, m - 1\}$  gibt es mindestens ein  $k \in U$ , so dass  $h(k) = y$ .

# Hash Function

## Definition

Eine Hash Function (*Hashfunktion*)

$$h : U \rightarrow \{0, 1, \dots, m - 1\}$$

bildet ein Universum  $U$  von Schlüsseln beliebigen Typs auf  $m$  natürliche Zahlen ab.

Eigenschaften:

- total: Jeder Schlüssel  $k$  aus  $U$  hat genau einen Funktionswert  $h(k)$  in  $\{0, 1, \dots, m - 1\}$ .
- surjektiv: Für alle  $y \in \{0, 1, \dots, m - 1\}$  gibt es mindestens ein  $k \in U$ , so dass  $h(k) = y$ .

## Problemspezifikation

Problem: Hashing

Instanz:  $k$ . Ein Schlüssel aus  $U$ .

Lösung:  $i$ . Ein Wert aus  $\{0, 1, \dots, m - 1\}$ , der  $k$  deterministisch zugewiesen wird.

Wunsch: Eine Funktionsvorschrift oder ein Algorithmus, der das Hashingproblem für alle  $k \in U$  so löst, dass Anwendungsanforderungen erfüllt werden.

# Hash Function

## Anwendungen

### 1. Dictionary / Mengen

Ungeordnete Speicherung von Elementen unter einem eindeutigen Schlüssel bei Ausschluss von Duplikaten.

### 2. Ähnlichkeitssuche / Partitionierung

Unterteilung von Elementen in Äquivalenzklassen, bestehend aus *ähnlichen* Elementen.

### 3. Datenintegritätstest / Kryptographie

Sicherstellung der Echtheit einer Nachricht durch Abgleich mit einem Prüfwert.

# Hash Function

## Anwendungen

### 1. Dictionary / Mengen

Ungeordnete Speicherung von Elementen unter einem eindeutigen Schlüssel bei Ausschluss von Duplikaten.

### 2. Ähnlichkeitssuche / Partitionierung

Unterteilung von Elementen in Äquivalenzklassen, bestehend aus *ähnlichen* Elementen.

### 3. Datenintegritätstest / Kryptographie

Sicherstellung der Echtheit einer Nachricht durch Abgleich mit einem Prüfwert.

## Anforderungen gemäß Anwendung

### 1. Simple Uniform Hashing und Normalisierung

Kollisionen sollen schlimmstenfalls zufällig gleichverteilt auftreten, unabhängig von der Verteilung der Schlüssel in  $U$ .

### 2. Ähnlichkeitssensitivität

Kollisionen sollen genau dann auftreten, wenn sich zwei Schlüssel aus  $U$  ähnlich sind.

### 3. Kollisionsresistenz und Unumkehrbarkeit

Kollisionen sollen mit an Sicherheit grenzender Wahrscheinlichkeit unmöglich sein. Aus Hashwerten sollen die ursprünglichen Schlüssel nicht rekonstruiert werden können.

# Hash Function

## Anwendungen

### 1. Dictionary / Mengen

Ungeordnete Speicherung von Elementen unter einem eindeutigen Schlüssel bei Ausschluss von Duplikaten.

### 2. Ähnlichkeitssuche / Partitionierung

Unterteilung von Elementen in Äquivalenzklassen, bestehend aus *ähnlichen* Elementen.

### 3. Datenintegritätstest / Kryptographie

Sicherstellung der Echtheit einer Nachricht durch Abgleich mit einem Prüfwert.

## Anforderungen gemäß Anwendung

### 1. Simple Uniform Hashing und Normalisierung

Kollisionen sollen schlimmstenfalls zufällig gleichverteilt auftreten, unabhängig von der Verteilung der Schlüssel in  $U$ .

### 2. Ähnlichkeitssensitivität

Kollisionen sollen genau dann auftreten, wenn sich zwei Schlüssel aus  $U$  ähnlich sind.

### 3. Kollisionsresistenz und Unumkehrbarkeit

Kollisionen sollen mit an Sicherheit grenzender Wahrscheinlichkeit unmöglich sein. Aus Hashwerten sollen die ursprünglichen Schlüssel nicht rekonstruiert werden können.

# Hash Function

## Hash Tables

Problem: Hashing

Instanz:  $k$ . Ein Schlüssel aus  $U$ .

Lösung:  $i$ . Ein Wert aus  $\{0, 1, \dots, m - 1\}$ , der  $k$  deterministisch zugewiesen wird.

Wunsch: Eine Funktionsvorschrift oder ein Algorithmus, der das Hashingproblem für alle  $k \in U$  gemäß Simple Uniform Hashing löst.

# Hash Function

## Hash Tables

Problem: Hashing

Instanz:  $k$ . Ein Schlüssel aus  $U$ .

Lösung:  $i$ . Ein Wert aus  $\{0, 1, \dots, m - 1\}$ , der  $k$  deterministisch zugewiesen wird.

Wunsch: Eine Funktionsvorschrift oder ein Algorithmus, der das Hashingproblem für alle  $k \in U$  gemäß Simple Uniform Hashing löst.

Praktische Probleme:

- ❑ Das Universum der Schlüssel kann Schlüssel aller Datentypen enthalten.
- ❑ Die Schlüsselverteilung unbekannt.



# Hash Function

## Hash Tables

Problem: Hashing

Instanz:  $k$ . Ein Schlüssel aus  $U$ .

Lösung:  $i$ . Ein Wert aus  $\{0, 1, \dots, m - 1\}$ , der  $k$  deterministisch zugewiesen wird.

Wunsch: Eine Funktionsvorschrift oder ein Algorithmus, der das Hashingproblem für alle  $k \in U$  gemäß Simple Uniform Hashing löst.

Praktische Probleme:

- ❑ Das Universum der Schlüssel kann Schlüssel aller Datentypen enthalten.
- ❑ Die Schlüsselverteilung unbekannt.

Heuristiken für Hashfunktionen:

- ❑ Divisionsrestmethode
- ❑ Multiplikative Methode
- ❑ Universelles Hashing

# Hash Function

## Vorverarbeitung

Das Universum  $U$  kann auf die natürlichen Zahlen  $\mathbf{N}$  abgebildet werden:

$$h : \mathbf{N} \rightarrow \{0, 1, \dots, m - 1\}$$

Die Abbildung ist abhängig vom Datentyp der Schlüssel in  $U$ .

# Hash Function

## Vorverarbeitung

Das Universum  $U$  kann auf die natürlichen Zahlen  $\mathbf{N}$  abgebildet werden:

$$h : \mathbf{N} \rightarrow \{0, 1, \dots, m - 1\}$$

Die Abbildung ist abhängig vom Datentyp der Schlüssel in  $U$ .

Beispiel:

- ❑ Sei  $U$  die Menge aller Wörter und Schlüssel  $k = \text{Turing}$  aus  $U$ .
- ❑ Zeichenketten (*Strings*) werden als Arrays von Zeichen repräsentiert.
- ❑ Zeichen sind auf Basis einer Kodierungstabelle als natürliche Zahlen kodiert.
- ❑ Jedem Zeichen ist ein Codepunkt in der Tabelle zugeordnet.
- ❑ Eine einfache Kodierungstabelle ist [ASCII](#): sie kodiert 128 Zeichen.
- ❑ Zeichenketten können als Zahl zur Basis 128 kodiert werden:

$$k = \underbrace{84}_{\text{T}} \cdot 128^5 + \underbrace{117}_{\text{u}} \cdot 128^4 + \underbrace{114}_{\text{r}} \cdot 128^3 + \underbrace{105}_{\text{i}} \cdot 128^2 + \underbrace{110}_{\text{n}} \cdot 128^1 + \underbrace{103}_{\text{g}} \cdot 128^0$$

# Hash Function

## Vorverarbeitung

Das Universum  $U$  kann auf die natürlichen Zahlen  $\mathbf{N}$  abgebildet werden:

$$h : \mathbf{N} \rightarrow \{0, 1, \dots, m - 1\}$$

Die Abbildung ist abhängig vom Datentyp der Schlüssel in  $U$ .

Beispiel:

- ❑ Sei  $U$  die Menge aller Wörter und Schlüssel  $k = \text{Turing}$  aus  $U$ .
- ❑ Zeichenketten (*Strings*) werden als Arrays von Zeichen repräsentiert.
- ❑ Zeichen sind auf Basis einer Kodierungstabelle als natürliche Zahlen kodiert.
- ❑ Jedem Zeichen ist ein Codepunkt in der Tabelle zugeordnet.
- ❑ Eine einfache Kodierungstabelle ist [ASCII](#): sie kodiert 128 Zeichen.
- ❑ Zeichenketten können als Zahl zur Basis 128 kodiert werden:

$$k = 2.917.865.781.095_{10}$$

## Bemerkungen:

- ❑ ASCII steht für „American Standard Code for Information Interchange“ und stellt einen frühen Standard zum Austausch von kodiertem Texten dar.

# Hash Function

## Divisionsrestmethode

Hashfunktion:

$$h(k) = k \bmod m,$$

wobei  $k$  ein Schlüssel aus  $U$  und  $m$  die Kapazität der Hash Table ist.

Beispiel: Für  $m = 12$  und  $k = 100$  ist  $h(k) = 4$ .

# Hash Function

## Divisionsrestmethode

Hashfunktion:

$$h(k) = k \bmod m,$$

wobei  $k$  ein Schlüssel aus  $U$  und  $m$  die Kapazität der Hash Table ist.

Beispiel: Für  $m = 12$  und  $k = 100$  ist  $h(k) = 4$ .

Eigenschaften:

- ❑ Sehr schnelle Berechnung; nur eine CPU-Instruktion.
- ❑ Die Kapazität  $m$  der Hash Table beeinflusst die Kollisionswahrscheinlichkeit:
  - Wenn  $m$  gerade ist, dann entspricht die Parität von  $h(k)$  der von  $k$ .
  - Wenn  $m = 2^p$ , dann entspricht  $h(k)$  nur den  $p$  niedrigstwertigen Bits.
  - Wenn  $m = 2^p - 1$  (Mersenne-Zahl) und  $k$  ein String zur Basis  $2^p$ , dann haben alle Permutationen einer Zeichenkette denselben Hashwert  $h(k)$ .
- ➔ Wenn  $m$  prim und stark verschieden von einer Zweierpotenz ist, verteilen sich die Hashwerte nahezu gleichmäßig.

## Bemerkungen:

- ❑ Der Modulo-Operator `mod` (auch `%`) ist eine Kurzform um die Division mit Rest auszudrücken. Für alle zwei ganzen Zahlen  $k$  und  $m \neq 0$  gibt es zwei eindeutige ganze Zahlen  $a$  und  $b$ , so dass  $k = ma + b$ , wobei  $0 \leq b < |m|$  für den Rest steht, der verbleibt, wenn man  $k$  durch  $m$  teilt.



# Hash Function

## Multiplikative Methode

Hashfunktion:

$$h(k) = \lfloor m(kc \bmod 1) \rfloor = \lfloor m(kc - \lfloor kc \rfloor) \rfloor,$$

wobei  $k$  ein Schlüssel aus  $U$ ,  $m$  die Kapazität der Hash Table, und  $0 < c < 1$  eine Konstante ist.

# Hash Function

## Multiplikative Methode

Hashfunktion:

$$h(k) = \lfloor m(kc \bmod 1) \rfloor = \lfloor m(kc - \lfloor kc \rfloor) \rfloor,$$

wobei  $k$  ein Schlüssel aus  $U$ ,  $m$  die Kapazität der Hash Table, und  $0 < c < 1$  eine Konstante ist.

Eigenschaften:

- ❑ Die Parameter  $m$  und  $c$  können unabhängig voneinander gewählt werden.
  - ❑ Die Wahl von  $m$  ist unkritisch.
  - ❑ Die Wahl von  $c$  beeinflusst die Kollisionswahrscheinlichkeit:
    - Wenn  $m$  eine Zweierpotenz und  $c = s/2^w$ , wobei  $0 < s < 2^w$  bei Wortgröße  $w$  ist, wird die Implementierung vereinfacht.
    - Wenn  $c = (\sqrt{5} - 1)/2 = 0.6180339887\dots$  ([Goldener Schnitt](#)), verteilen sich die Hashwerte nahezu gleichmäßig.
- Wähle  $c = s/2^w$  nahe zu  $(\sqrt{5} - 1)/2$  (z.B.  $2654435769/2^{32}$  bei  $w = 32$ )

# Hash Function


## Multiplikative Methode

Hashfunktion:

$$h(k) = \lfloor m(kc \bmod 1) \rfloor = \lfloor m(kc - \lfloor kc \rfloor) \rfloor,$$

wobei  $k$  ein Schlüssel aus  $U$ ,  $m$  die Kapazität der Hash Table, und  $0 < c < 1$  eine Konstante ist.

Implementierung im Dualsystem für  $m = 2^p$ :



# Hash Function

## Multiplikative Methode

Hashfunktion:

$$h(k) = \lfloor m(kc \bmod 1) \rfloor = \lfloor m(kc - \lfloor kc \rfloor) \rfloor,$$

wobei  $k$  ein Schlüssel aus  $U$ ,  $m$  die Kapazität der Hash Table, und  $0 < c < 1$  eine Konstante ist.

Beispiel:

- Sei  $m = 2^3 = 8$ ,  $p = 3$ ,  $w = 5$ , und  $k = 21$ .

Es muss  $0 < s < 2^5$  gelten; wähle  $s = 13$ , so dass  $c = 13/32$ .

- Formelbasiert:

$$kc = 21 \cdot \frac{13}{32} = \frac{273}{32} = 8\frac{17}{32}$$

$$\Rightarrow kc \bmod 1 = \frac{17}{32}$$

$$\Rightarrow m(kc \bmod 1) = 8\frac{17}{32} = \frac{17}{4} = 4\frac{1}{4}$$

$$\Rightarrow \lfloor m(kc \bmod 1) \rfloor = 4$$

$$\Rightarrow h(k) = 4$$

- Implementierungsbasiert:

$$ks = 21 \cdot 13 = 273 = 8 \cdot 2^5 + 17$$

$$\Rightarrow r_1 = 8, r_0 = 17$$

$$\Rightarrow r_0 = 10001_2$$

$$\Rightarrow h(k) = 100_2$$

$$\Rightarrow h(k) = 4$$

# Hash Function

## Universal Hashing

Gedankenspiel:

- ❑ Sei  $h$  die für eine Hash-Table-Implementierung festgelegte Hashfunktion.
  - ❑ Dann kann ein böswilliger Nutzer (**Adversary** [*Gegenspieler*])  $n$  Schlüssel aus  $U$  wählen, so dass alle ihre mit  $h$  berechneten Hashwerte kollidieren.
- Die Average-Case-Laufzeit kann nicht garantiert werden.

# Hash Function

## Universal Hashing

Gedankenspiel:

- ❑ Sei  $h$  die für eine Hash-Table-Implementierung festgelegte Hashfunktion.
  - ❑ Dann kann ein böswilliger Nutzer (**Adversary** [*Gegenspieler*])  $n$  Schlüssel aus  $U$  wählen, so dass alle ihre mit  $h$  berechneten Hashwerte kollidieren.
- Die Average-Case-Laufzeit kann nicht garantiert werden.

Gegenmaßnahme: Randomisierung

- ❑ Wähle zufällig eine andere Hashfunktion  $h$  vor jeder Nutzung.
- ❑ Solange der Adversary nicht vorhersagen kann, welche Funktion gewählt wird, kann die Average-Case-Laufzeit erwartet werden.

# Hash Function

## Universal Hashing

Gedankenspiel:

- ❑ Sei  $h$  die für eine Hash-Table-Implementierung festgelegte Hashfunktion.
  - ❑ Dann kann ein böswilliger Nutzer (**Adversary** [*Gegenspieler*])  $n$  Schlüssel aus  $U$  wählen, so dass alle ihre mit  $h$  berechneten Hashwerte kollidieren.
- Die Average-Case-Laufzeit kann nicht garantiert werden.

Gegenmaßnahme: Randomisierung

- ❑ Wähle zufällig eine andere Hashfunktion  $h$  vor jeder Nutzung.
- ❑ Solange der Adversary nicht vorhersagen kann, welche Funktion gewählt wird, kann die Average-Case-Laufzeit erwartet werden.

Probleme:

- ❑ Anzahl Funktionen von  $U$  nach  $m$ :  $m^{|U|} \rightarrow |U| \lg m$  bits pro Funktion.
  - ❑ Zahlreiche mögliche Hashfunktionen haben nachteilige Eigenschaften.
- Konstruiere eine handhabbar große Familie von guten Hashfunktionen.

# Hash Function

## Universal Hashing: Definition

Sei  $H$  eine endliche Familie (Menge) von Hashfunktionen, die  $U$  auf  $\{0, 1, \dots, m-1\}$  abbilden. Wir nennen  $H$   **$c$ -universell**, wenn für alle Schlüssel  $k, l \in U$  die Zahl der Hashfunktionen  $h \in H$ , so dass  $h(k) = h(l)$ , höchstens  $c/m \cdot |H|$  ist.

→ Für ein zufälliges  $h$  aus  $H$  beträgt die Wahrscheinlichkeit  $c/m$ , dass  $h(k) = h(l)$ .

### Satz 3 (Average-Case-Laufzeit III)

In einer Hash Table, in der Kollisionen mit Chaining behandelt und eine zufällige Hashfunktion aus einer Familie  $c$ -universeller Hashfunktionen verwendet wird, ist die Average-Case-Laufzeit bei erfolgreicher und erfolgloser Suche in  $\Theta(1 + c\alpha)$ .

Beweis: Analog zu Average-Case-Laufzeit I und II.

Der Hauptunterschied ist, dass der Analyse hier ein anderes Zufallsexperiment zugrundeliegt, nämlich das, eine Funktion  $h$  aus  $H$  zufällig zu wählen.



# Hash Function

## Universal Hashing: Hashfunktion I

Sei Hashfunktion  $h_{\mathbf{a}}$  definiert als

$$h_{\mathbf{a}}(\mathbf{k}) = \mathbf{a}^T \mathbf{k} \bmod p,$$

wobei

- $\mathbf{a} = (a_1, \dots, a_s)$  ein Vektor von Zufallszahlen mit  $0 \leq a_i < p$ ,
- $\mathbf{k} = (k_1, \dots, k_s)$  ein Vektor von Bestandteilen von Schlüssel  $k$ ,
- $\mathbf{a}^T$  die Transposition von  $\mathbf{a}$ ,
- $\mathbf{a}^T \mathbf{k} = \sum_{i=1}^s a_i k_i$  das Skalarprodukt der beiden Vektoren,
- und  $p$  eine Primzahl ist.

# Hash Function

## Universal Hashing: Hashfunktion I

Sei Hashfunktion  $h_a$  definiert als

$$h_a(\mathbf{k}) = \mathbf{a}^T \mathbf{k} \bmod p,$$

wobei

- ❑  $\mathbf{a} = (a_1, \dots, a_s)$  ein Vektor von Zufallszahlen mit  $0 \leq a_i < p$ ,
- ❑  $\mathbf{k} = (k_1, \dots, k_s)$  ein Vektor von Bestandteilen von Schlüssel  $k$ ,
- ❑  $\mathbf{a}^T$  die Transposition von  $\mathbf{a}$ ,
- ❑  $\mathbf{a}^T \mathbf{k} = \sum_{i=1}^s a_i k_i$  das Skalarprodukt der beiden Vektoren,
- ❑ und  $p$  eine Primzahl ist.

Beispiel:



# Hash Function

## Universal Hashing: Hashfunktion I

Sei Hashfunktion  $h_{\mathbf{a}}$  definiert als

$$h_{\mathbf{a}}(\mathbf{k}) = \mathbf{a}^T \mathbf{k} \bmod p,$$

wobei

- ❑  $\mathbf{a} = (a_1, \dots, a_s)$  ein Vektor von Zufallszahlen mit  $0 \leq a_i < p$ ,
- ❑  $\mathbf{k} = (k_1, \dots, k_s)$  ein Vektor von Bestandteilen von Schlüssel  $k$ ,
- ❑  $\mathbf{a}^T$  die Transposition von  $\mathbf{a}$ ,
- ❑  $\mathbf{a}^T \mathbf{k} = \sum_{i=1}^s a_i k_i$  das Skalarprodukt der beiden Vektoren,
- ❑ und  $p$  eine Primzahl ist.

Beispiel:



$\underbrace{\hspace{10em}}$   
 $\lfloor \lg p \rfloor$  bits  
 $\Rightarrow s = w / \lfloor \lg p \rfloor$

# Hash Function

## Universal Hashing: Hashfunktion I

Sei Hashfunktion  $h_a$  definiert als

$$h_a(\mathbf{k}) = \mathbf{a}^T \mathbf{k} \bmod p,$$

wobei

- ❑  $\mathbf{a} = (a_1, \dots, a_s)$  ein Vektor von Zufallszahlen mit  $0 \leq a_i < p$ ,
- ❑  $\mathbf{k} = (k_1, \dots, k_s)$  ein Vektor von Bestandteilen von Schlüssel  $k$ ,
- ❑  $\mathbf{a}^T$  die Transposition von  $\mathbf{a}$ ,
- ❑  $\mathbf{a}^T \mathbf{k} = \sum_{i=1}^s a_i k_i$  das Skalarprodukt der beiden Vektoren,
- ❑ und  $p$  eine Primzahl ist.

Beispiel:

	$k_1$	$k_2$	$\dots$	$k_s$
	•	•	$\dots$	•
	$a_1$	$a_2$	$\dots$	$a_s$
	=	=	$\dots$	=
$\Sigma$	$x_1$	$x_2$	$\dots$	$x_s$

$$= h(k)$$

# Hash Function

## Universal Hashing: Hashfunktion I

Sei Hashfunktion  $h_{\mathbf{a}}$  definiert als

$$h_{\mathbf{a}}(\mathbf{k}) = \mathbf{a}^T \mathbf{k} \bmod p,$$

wobei

- ❑  $\mathbf{a} = (a_1, \dots, a_s)$  ein Vektor von Zufallszahlen mit  $0 \leq a_i < p$ ,
- ❑  $\mathbf{k} = (k_1, \dots, k_s)$  ein Vektor von Bestandteilen von Schlüssel  $k$ ,
- ❑  $\mathbf{a}^T$  die Transposition von  $\mathbf{a}$ ,
- ❑  $\mathbf{a}^T \mathbf{k} = \sum_{i=1}^s a_i k_i$  das Skalarprodukt der beiden Vektoren,
- ❑ und  $p$  eine Primzahl ist.

### Satz 4 (Universelle Hashfunktionen I)

Die Familie von Hashfunktionen

$$H_1 = \{h_{\mathbf{a}} \mid \mathbf{a} \in \{0, 1, \dots, p-1\}^s\}$$

ist 1-universell, wenn  $p$  eine Primzahl ist.

Beweisidee: Abschätzung der Wahrscheinlichkeit, dass  $h(\mathbf{k}_1) = h(\mathbf{k}_2)$ .

# Hash Function

## Universal Hashing: Hashfunktion II

Sei Hashfunktion  $h_{a,b}$  definiert als

$$h_{a,b}(k) = ((ak + b) \bmod p) \bmod m,$$

wobei

- ❑  $a \in \{1, 2, \dots, p-1\} = \mathbf{Z}_p^*$ ,
- ❑  $b \in \{0, 1, \dots, p-1\} = \mathbf{Z}_p$ ,
- ❑  $p$  eine Primzahl,
- ❑ und  $m < p$  die Kapazität der Hash Table.

# Hash Function

## Universal Hashing: Hashfunktion II

Sei Hashfunktion  $h_{a,b}$  definiert als

$$h_{a,b}(k) = ((ak + b) \bmod p) \bmod m,$$

wobei

- $a \in \{1, 2, \dots, p-1\} = \mathbf{Z}_p^*$ ,
- $b \in \{0, 1, \dots, p-1\} = \mathbf{Z}_p$ ,
- $p$  eine Primzahl,
- und  $m < p$  die Kapazität der Hash Table.

### Satz 5 (Universelle Hashfunktionen II)

Die Familie von Hashfunktionen

$$H_2 = \{h_{a,b} \mid a \in \mathbf{Z}_p^* \text{ and } b \in \mathbf{Z}_p\}$$

ist 1-universell, wenn  $p$  eine Primzahl ist.

Beweisidee: Abschätzung der Wahrscheinlichkeit, dass  $h(k_1) = h(k_2)$ .

## Bemerkungen:

- Für jede Zahl  $\alpha > 1$  und jede nicht zu kleine natürliche Zahl  $m$  enthält das Intervall  $[m, \alpha m]$  etwa  $(\alpha - 1)m / \ln m$  Primzahlen. Es genügt also für häufig genutzte Intervalle, Tabellen mit eine Reihe von Primzahlen bereitzustellen. Auch die Suche nach einer Primzahl in einem Intervall ist möglich.



# Hash Function

## Perfect Hashing

Voraussetzung:

- ❑ Die Menge  $K \subseteq U$  tatsächlich benötigter Schlüssel ist vollständig bekannt.
  - ❑  $K$  ist statisch; es werden weder Elemente hinzugefügt noch gelöscht.
- Wunsch: Vermeidung von Hashkollisionen.

# Hash Function

## Perfect Hashing

Voraussetzung:

- ❑ Die Menge  $K \subseteq U$  tatsächlich benötigter Schlüssel ist vollständig bekannt.
- ❑  $K$  ist statisch; es werden weder Elemente hinzugefügt noch gelöscht.
- Wunsch: Vermeidung von Hashkollisionen.


## Konstruktion

- ❑ Sei  $H$  eine Familie universeller Hashfunktionen.
- ❑ Verteilung der  $n$  Schlüssel auf die  $m = n = |K|$  Slots und  $h \in H$ .
- ❑ Wenn der  $i$ -te Slot  $n_i > 0$  Elemente erhält: Wähle solange ein  $h_i \in H$ , bis die Schlüssel kollisionsfrei auf  $m_i = n_i^2$  Slots verteilen.

# Hash Function

## Perfect Hashing

Beispiel für  $K = \{10, 22, 37, 40, 52, 60, 70, 72, 75\}$  und  $h_{3,42}$ ,  $p = 101$  und  $m = 9$ :



Wenn  $m_j = n_j = 1$  genügt die Hashfunktion mit  $a = b = 0$

# Hash Function

## Perfect Hashing: Analyse

### Satz 6 (Perfekte Hashfunktionen I)

Wenn  $n$  Schlüssel mit einer Hashfunktion  $h$ , die zufällig aus einer Familie universeller Hashfunktionen gezogen wurde, auf  $m = n^2$  Slots verteilt werden, ist die Wahrscheinlichkeit für eine Hashkollision kleiner als  $1/2$ .

Beweisidee: Abschätzung der erwarteten Zahl von Kollisionen für  $n$  Schlüssel unter universellem Hashing bei  $n^2$  möglichen Slots.

# Hash Function

## Perfect Hashing: Analyse

### Satz 6 (Perfekte Hashfunktionen I)

Wenn  $n$  Schlüssel mit einer Hashfunktion  $h$ , die zufällig aus einer Familie universeller Hashfunktionen gezogen wurde, auf  $m = n^2$  Slots verteilt werden, ist die Wahrscheinlichkeit für eine Hashkollision kleiner als  $1/2$ .

Beweisidee: Abschätzung der erwarteten Zahl von Kollisionen für  $n$  Schlüssel unter universellem Hashing bei  $n^2$  möglichen Slots.

### Satz 7 (Perfekte Hashfunktionen II)

Wenn  $n$  Schlüssel mit einer Hashfunktion  $h$ , die zufällig aus einer Familie universeller Hashfunktionen gezogen wurde, auf  $m = n$  Slots verteilt werden, und die Größe der sekundären Hash Tables  $m_i = n_i^2$  für  $i = 0, 1, \dots, m - 1$ , dann ist die Wahrscheinlichkeit, dass der kumulierte Platzverbrauch der sekundären Hash Tables  $4n$  übersteigt, kleiner als  $1/2$ .

Beweisidee: Abschätzung der erwarteten Summe der benötigten Kapazitäten  $n_j^2$  für alle  $j = 0, 1, \dots, m - 1$  benötigten sekundären Hash Tables.